实验一 信息检索部分

实验要求

本次实验要求分组完成，每组最多 3 人（可以少于 3 人，但无优惠政策）。

根据本课程**信息检索部分**内容（对应第 2-9 周课程），完成以下实验：

- 【必做】分词与规范化处理
- 【必做】倒排表的构建
- 【必做】倒排表的扩展与优化
- 【必做】多种形式的信息检索
- 【选做】基于用户画像的个性化检索/推荐

数据背景

本次实验的数据来自清华大学智能技术与系统国家重点实验室信息检索课题组（THUIR）与小红书联合开源的 Qilin 数据集，该数据集是面向搜索、推荐和检索增强生成研究的公开多模态数据集，包含笔记内容、匿名用户特征、搜索与推荐日志，以及点击、点赞、收藏等行为反馈。原始数据集包含约 198 万篇笔记、1.55 万名用户、5.02 万条搜索记录和 9.46 万条推荐记录。

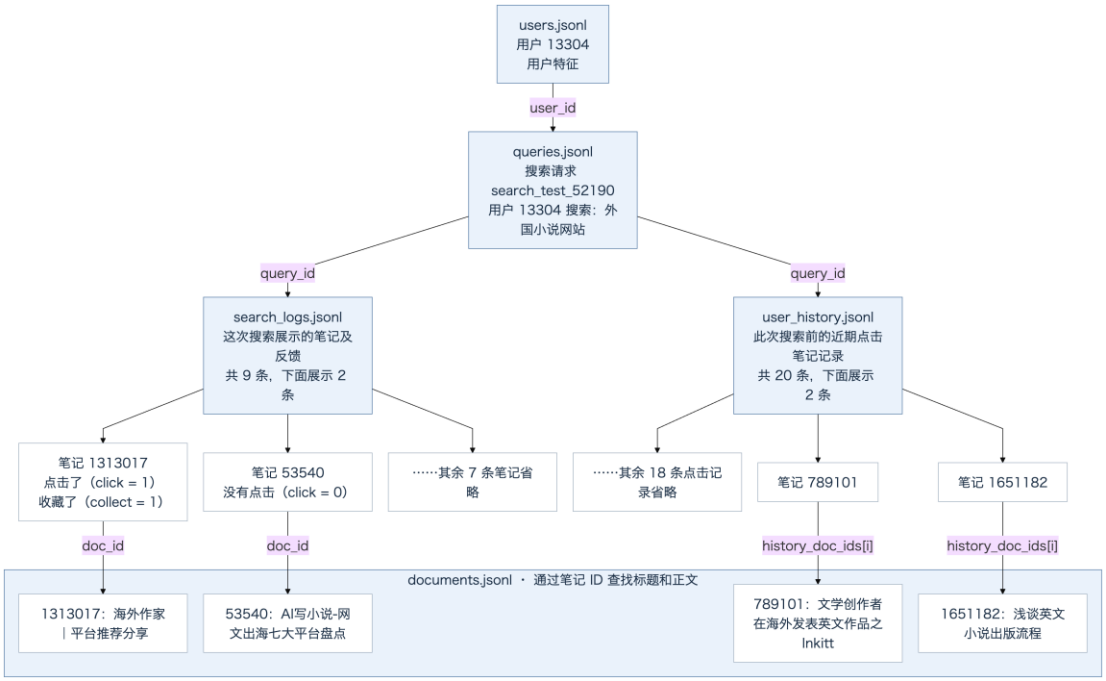
官方数据集链接：https://huggingface.co/datasets/THUIR/Qilin

考虑到原始数据量较大，为便于进行课程实验，我们对其进行了预处理，并从中抽取出 **Qilin-IR-50K 教学子集**作为本次实验使用的数据，包含 50,000 篇中文笔记及相关搜索请求、用户特征和行为记录。预处理流程如下：我们从 Qilin 原始数据中筛选查询、正文及行为记录有效的搜索请求，按用户抽样，保留相关曝光与历史笔记，并随机补充背景笔记，形成 5 万篇文档库；统一字段和缺失值表示，转换为 JSONL 格式，同时整理用户行为及选做任务的参考训练/测试划分。标题和正文保持原样，未分词、未去停用词、未截断。

具体而言，Qilin-IR-50K 含以下 7 个数据文件：

文件	规模	内容与用途
documents.jsonl	50,000 篇	笔记 ID、标题、正文；任务 1—4 的文档库。
queries.jsonl	1,941 次请求	查询文本、用户 ID 等；提供真实搜索示例。
search_logs.jsonl	18,763 条检索记录	每次搜索展示了哪些笔记，以及点击、点赞、收藏等反馈。
user_history.jsonl	1,941 条	用户每次搜索时，对应的近期点击笔记列表。
users.jsonl	9,769 位用户	用户 ID 和用户特征，用于个性化检索与推荐。
optional/rating_pairs.jsonl	172,950 对	聚合后的用户—笔记行为及训练/测试标签。
optional/feedback_events.jsonl	186,486 条事件	聚合前的行为事件子集。

下面用一条真实搜索记录为例，说明各数据文件之间的关系。



实验内容

前排友情提示：

（1） 选做内容不影响分数，请根据时间及兴趣量力而行，如无精力可以不做。

（2） 可根据课程中介绍的方法进行实验，也可根据自己掌握的知识修改方案，但请注意不要内卷。

1. 【必做】文档分词与规范化处理

在获取实验所需的文档后，需要从 json 文档中提取出所需的内容，并进行分词和规范化处理。具体流程包括：

（1） **分词：**读取 documents.jsonl 文件中的标题（title）和正文（content），分别采用基于匹配的分词方法和基于统计的分词方法，并对两种方法的分词结果进行对比分析。可以根据课程内容自行编制代码，也可以调用工具包。标题和正文可分别处理，也可合并处理，请在实验报告中说明所采用的处理方式。

（2） **规范化处理：**基于课程内容，对分词结果进行规范化处理，形成规范化词项（Token），包括但不限于停用词处理、数字、标点符号及其他特殊字符处理，以及适用的归一化处理。该部分可手动编写规则，也可以调用工具包。（注：请保留去除与保留停用词两种不同设置下的结果，以支持任务 4 中的对照分析。）

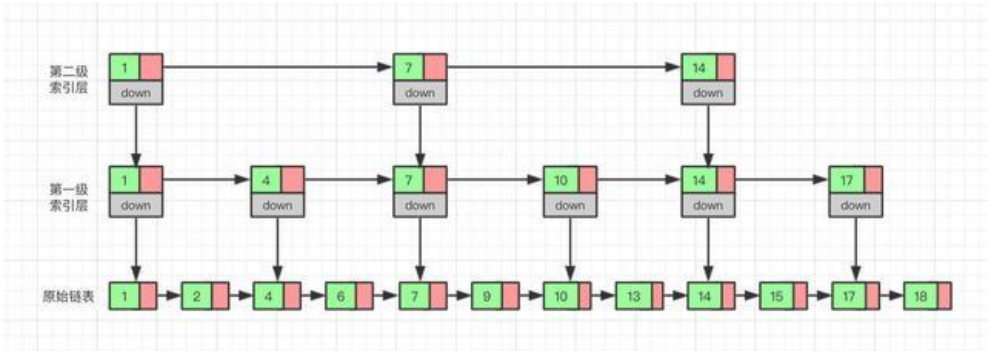
2. 【必做】倒排表的构建

基于前一阶段形成的分词结果，在经过预处理的数据集上建立倒排索引表，并尝试形成相应的跳表指针。具体流程包括：

（1） 根据第 4 节课内容，对前一部分所获得的所有文档中的所有规范化词项构建倒排表。

（2） 为实现面向倒排表的快速检索，设计合适的跳表指针。

（3） **【选做】**感兴趣的同学可以查看 Skip List[1] 对应的论文，设计多层跳表指针，并比较与单层跳表指针的性能和开支差异。



[1] William Pugh, *Skip lists: a probabilistic alternative to balanced trees*, Communications of the ACM, 1990, 33(6), 668-676.

3. 【必做】倒排表的扩展与优化

根据第 4 节课后半部分的内容，尝试对前一阶段所构建的倒排表进行扩展与优化。具体流程包括：

（1） 在倒排表中加入词项位置信息，以应对短语或特定句式模版检索需求。

（2） 任选两种课程中介绍过的索引压缩方法加以实现，如按块存储、前端编码等，并比较压缩后的索引在存储空间上与原索引的区别。

4. 【必做】多种形式的信息检索

根据课程的内容，尝试对先前生成的文档库进行检索实践。注意：本环节所涉及的查询条件（Query）自行设计。具体流程包括：

A. 布尔检索

（1） 自行设计不少于 3 种复杂查询条件，以布尔表达式的形式呈现。并通过实验分析同一个布尔表达式的不同处理顺序对时间开支的影响。

（2） 根据倒排表进行检索，并比较索引压缩前后在检索效率上的差异。

（3） 至少设计 1 次面向短语的检索，并分析加入词项位置信息的扩展倒排表在应对短语检索任务时的效果。

（4） 选择不同的跳表指针步长，并分析其对存储性能/检索效率的影响。

B. **向量空间模型：**自行设计查询条件，计算查询条件与文档的 TF-IDF 值，通过向量空间模型进行文档检索实践。

C. **基于文档表征的检索：**自行选择合适的预训练模型或大语言模型，对完整段落和查询进行表征，基于表征与相似性计算实现文档检索，并与向量空间模型的检索效果进行比较。其中需要包括以下内容：

（1） 在相同模型及其他设置下，对比文本不预先分词与预先分词两种输入方式对检索结果造成的影响，并结合具体案例分析分词是否影响语义理解和检索结果。（注：这里的“预先分词”指在输入模型前额外进行中文分词，将得到的各个词项分别输入模型，再将各词项的表征聚合为文本表征；“不预先分词”指直接将原文输入模型，获取文本表征。两种方式在编码过程中均使用模型自带的 tokenizer。）

（2） 对比保留与去除停用词时的检索结果，并分析其影响。请说明所使用的停用词表或规则。

5. 【选做】基于用户画像的个性化检索/推荐

根据课程的内容，利用数据中的用户信息及点击（click）、收藏（collect）、点赞（like）等行为反馈，自行定义行为到评分的映射，将其转化为推荐或评分预测任务。该部分实验鼓励自由探索，以下提供一种思路供参考：

（1） 从 optional/rating_pairs.jsonl 中读取用户—文档对及行为标记，按统一规则生成评分。例如，可定义评分如下：

行为	评分
Click	1
Like	2
Collect	3

也可自行设计其他映射，并说明依据。注：该评分表示人为定义的行为强度，不是用户真实打分。

（2） 采用协同过滤方式，仅利用用户—文档评分矩阵进行推荐或评分预测。可以自行在基本协同过滤的基础上添加部分策略，如考虑评分的情境或周期性等因素，并讨论这些因素会对排序精度产生何种影响。

（3） 充分利用更丰富的信息，如笔记标题、正文及可用的用户特征等，构建更复杂的模型进行预测。

注意：请结合预测结果分析方法的有效性。当然，也可采用在文件中提供的参考划分。（划分说明：文件中的 split 字段已标明每个用户—笔记对属于训练集还是测试集。以及，该划分用于随机矩阵补全，训练集和测试集不是按时间先后划分的，因此不能将其理解为“用过去的行为预测未来的行为”。）

请自行选择本次实验的评价指标，不做统一要求。（坚决反卷！）

提交说明

请于截止日期（**2026 年 11 月 1 日晚 23:59**）以前提交到课程邮箱 **ustcweb2026@163.com**，具体要求如下：

1. 请在邮件中提交实验报告，并将实验代码、索引文件和其他你认为有必要提交的附件上传至科大云盘（https://pan.ustc.edu.cn）以备检查。请将云盘的链接填入实验报告中。
2. 邮件标题以及压缩包以"组长学号-组长姓名-Web 信息处理实验 1"格式命名。邮件正文及实验报告正文中请列出小组所有成员的姓名、学号。因未署名造成统计遗漏责任自行承担。你可以将邮件抄送你的队友。
3. 实验报告请务必独立完成，如果发现抄袭按 0 分处理。
4. 迟交实验将不被接收。
5. 实验过程中，如果对数据集或实验设置有任何疑问，欢迎随时联系助教交流。